Ciência de Dados Responsável

UFSCar Sorocaba
Novembro, 2026
Giovana Morais

por que esse curso?

- temos que ter clareza sobre o impacto das ferramentas que desenvolvemos.
- não existe neutralidade. isso torna as coisas mais difíceis, mas não impossíveis.
- precisamos ser críticos porque o momento de mudança é literalmente agora.

carteirada

- Cientista da Computação (UFSCar Sorocaba)
- Mestra em Ciência da Computação (IME-USP)
- Doutoranda em… Ciência da Computação (NYU)



- interesses de pesquisa:
  - extração de informação musical
  - explicabilidade de modelos multimodais
  - ciência de dados e IA responsável



(perdemos feio)

logística

- quatro encontros, 2h cada, sem avaliações
- cada encontro tem um componente teórico e um componente prático
- página com informações e materiais: giovana-morais.github.io/ciencia_de_dados_responsavel
- monitora/minha grande salvadora: Giovanna Gaeta

antes de começarmos

- **nuance**: não existe nada 100% certo ou errado.
- pontos de vistas diferentes são válidos. vamos falar sobre ética e sobre diferentes abordagens filosóficas para uma mesma questão.
- esse é um espaço de discussão.

Encontro 1: O Mito da Neutralidade e Justiça Algorítmica

a promessa da IA

- dados brutos → algoritmos sem viés humana → IA é uma solução neutra
- automatizar processos humanos, garantindo justiça e agilidade

máquinas cometem erros

- alguns erros são aceitáveis
  - ex. você compra uma camiseta azul e recebe uma verde
- alguns erros são médio aceitáveis
  - um sistema automático de tradução muda o sentido original de uma sentença
- alguns erros são inaceitáveis
  - ex. seu currículo recebe menos peso pra uma vaga que requer mais experiência por você ser mulher

ótica de análise:

- quais são os **objetivos** de um sistema de decisão automatizada?
- quais são os **benefícios** e **quem** se beneficia?
- quais são os **malefícios** e **quem** é afetado?

discussão:



Quando o algoritmo é cruel: uma mulher negra e a violência silenciosa do LinkedIn

Bruna Crioula Follow 6 min read · Jun 16, 2025

- qual o objetivo de um sistema de recomendação de vagas? o que define “sucesso”?
- quem são as pessoas envolvidas? como esse sistema afeta elas?

https://brunacrioula.medium.com/quando-o-algoritmo-%C3%A9-cruel-uma-mulher-negra-e-a-viol%C3%AAncia-silenciosa-do-linkedin-d387a614d3aa

discussão:

Quando o algoritmo é cruel: uma mulher negra e a violência silenciosa do LinkedIn



Bruna Crioula Follow 6 min read · Jun 16, 2025

- LinkedIn diz pra uma mulher que as vagas que “mais combinam com ela” são vagas de auxiliar de serviços gerais.
- a mulher em questão é nutricionista e mestra em ciências sociais, além de ter experiências como pesquisadora, nutricionista, analista, e empresária.
- a plataforma afirmou que seus algoritmos são neutros, mas não ofereceu nenhuma auditoria dos seus sistemas.

https://brunacrioula.medium.com/quando-o-algoritmo-%C3%A9-cruel-uma-mulher-negra-e-a-viol%C3%AAncia-silenciosa-do-linkedin-d387a614d3aa

discussão:

- qual o objetivo de um sistema de recomendação de músicas e playlists? o que define sucesso aqui?
- quem são as pessoas afetadas e como elas são afetadas?



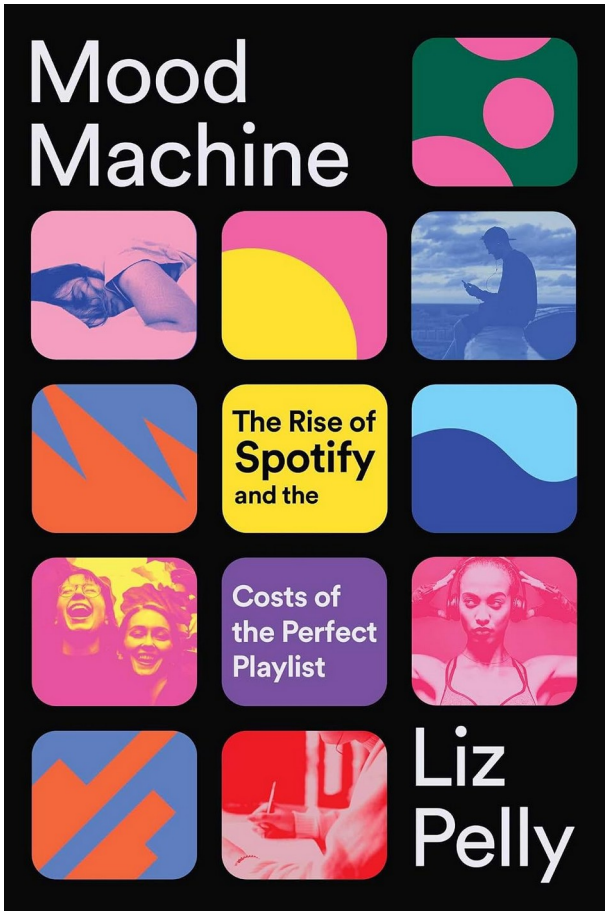
discussão:

- “skip rate”: o quanto as pessoas pulam a sua música antes dos primeiros 30s
- essa métrica interage com outras métricas da plataforma que ditam
  - quais playlists a sua música pode ou não aparecer
  - qual o seu “índice de popularidade”
- vira uma métrica a ser “gamificada”:
  - sua música tem que ser incrível nos primeiros 10s
  - se não for, “não vale a pena”
    - (mas quem decidiu isso???)

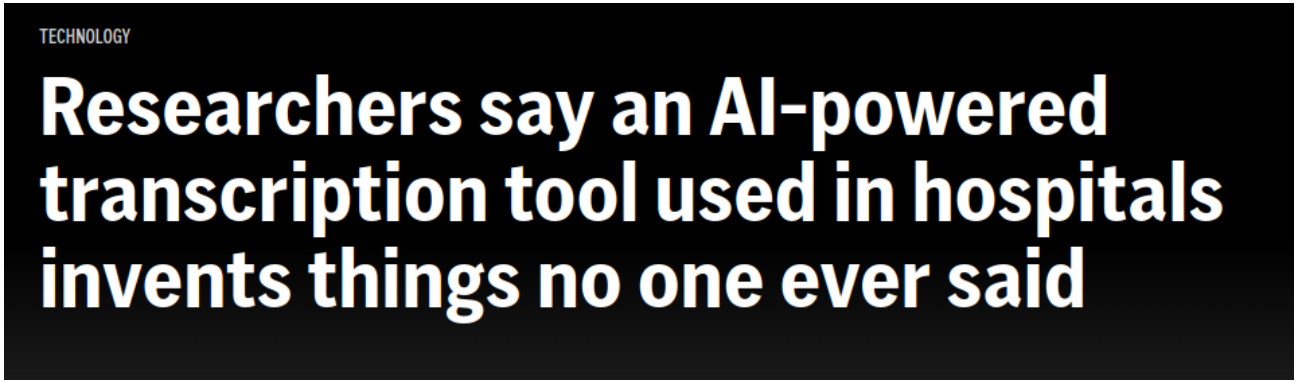


decisões que afetam indústrias

“Artistas independentes foram convencidos a conseguir seu sustento por meio de um sistema que não apenas foi desenvolvido para as grandes produtoras, como também prioriza as músicas feitas para um sucesso em grande escala. Mas nem todo artista tem o sucesso em grande escala quando escrevem, compõem e lançam suas músicas. Nem todo mundo que quer ter uma carreira musical quer ser uma estrela do pop.”



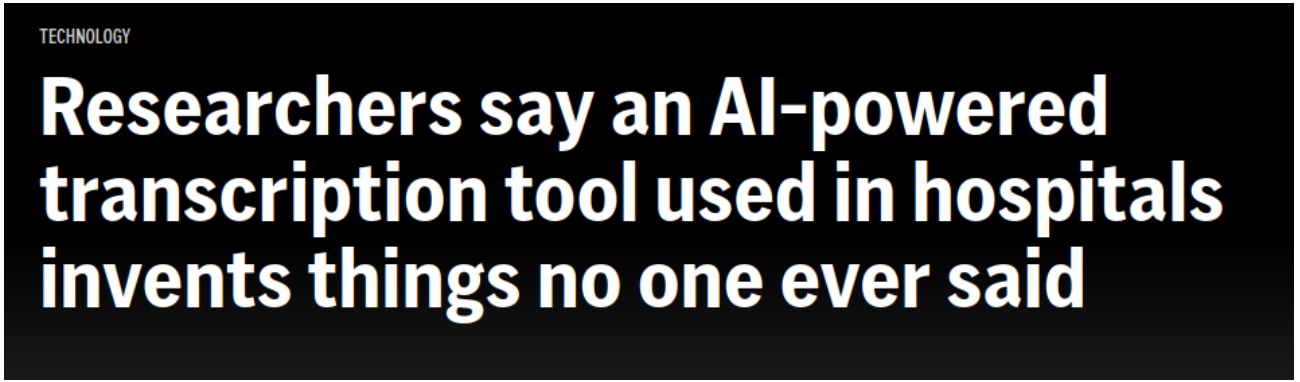
discussão:



- qual o objetivo de um modelo de transcrição? o que determina seu sucesso?
- quem são as pessoas envolvidas? como os resultados afetam essas pessoas?

https://apnews.com/article/ai-artificial-intelligence-health-business-90020cdf5fa16c79ca2e5b6c4c9bbb14

discussão:



- um modelo de transcrição “inventa” coisas que ninguém nunca disse
- o Whisper (modelo de transcrição) é atualmente o encoder de áudio usado em todos os maiores modelos grandes disponíveis: Qwen, ChatGPT entre outros.
- os erros só podem ser capturados quando há um ground truth. o que acontece quando esses modelos são usados em produção?
- privacidade: esses dados de transcrição têm que ser salvos em algum lugar...

https://apnews.com/article/ai-artificial-intelligence-health-business-90020cdf5fa16c79ca2e5b6c4c9bbb14

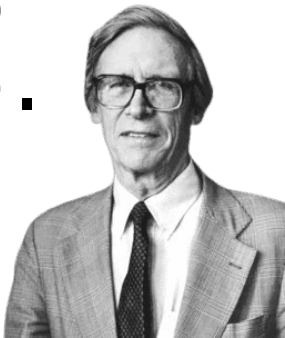
então o que é justiça?

experimento mental

- as regras da nossa sociedade agora serão todas decidida por você.
- CONTUDO: você não sabe qual será a sua posição nessa nova sociedade
  - você não sabe sua etnia, sua classe social, seu grau de escolaridade, nada.

o véu da ignorância

- o véu de John Rawls tira de você o que te enviesa.
- princípio da diferença: desigualdades só se justificam se beneficiarem os menos favorecidos.
- um sistema otimizado para acurácia média é *utilitarista*, e Rawls pergunta como ele se sai para o grupo pior atendido.



o viés é o seu padrão de existência no mundo

“que tende a seguir certo caminho, ou a agir de determinada maneira; tendência.”

- características que enviesam o meu modo de ser:
  - minha cultura
  - o lugar que eu nasci
  - a minha raça
  - a minha classe social
  - minha religião (ou falta de)
  - etc

experimento mental 2

- você tem que contratar uma pessoa pra ser estagiária.
- existem 10000 currículos pra serem filtrados antes mesmo de você iniciar sua entrevista.
- você tem uma semana pra escolher 5 pessoas pra entrevistar.
- por onde começar?

o viés algorítmico é um viés automatizado

- sistemas/modelos que discriminam de maneira **sistemática** e **injusta** um determinado grupo de indivíduos.
  - um sistema de crédito que nega aumento de crédito pra alguém que atrasa todos os seus pagamentos faz sentido.
  - um sistema de crédito que nega crédito pra alguém porque seu sobrenome é “étnico” é inaceitável porque esse atributo não tem relação nenhuma com o objetivo do sistema.

tipos de viés em sistemas automatizados

- **pré-existente**: existe independente do algoritmo, tem origem social
- **técnico**: introduzido ou exacerbado devido a características técnicas do sistema de decisão
- **emergente**: aparece no contexto de uso do sistema

viés pré-existente

- **Individual**: alguém responsável pelo design do sistema reproduz seus próprios vieses
- **Social**: vieses gerados pela sociedade. Ex. indústria, instituições ou cultura de um lugar.

viés técnico

- **Ferramentas de computação**: originado pela limitação de uma tecnologia (ex hardware)
- **Algoritmos descontextualizados:** o algoritmo trata todo mundo igual porque é ruim pra todo mundo (ex. algoritmo pra reservar voo que dá prioridade pra companias aéreas baseando-se na ordem alfabética dos nomes)
- **Geração de números aleatórios:** vieses gerados pela imperfeição da pseudo-aleatoriedade
- **Formalização de construções humanas:** quando tentamos transformar coisas humanas em dados palpáveis pra computadores (discurso, quantização etc)

viés emergente

- **Novo conhecimento social:** aprendemos algo que um modelo ainda não está incorporado no sistema
- **Diferença de uso planejado e uso real**
  - **Experiências diferentes:** o sistema assume um conhecimento que os usuários não têm
  - **Valores diferentes:** o sistema é usado por uma população com valores diferentes do sistema

os dados são apenas um espelho da realidade

dados não são neutros, mas e os algoritmos?

também não são!

- alguém escolhe as features que vão ser usadas ← **viés**
- alguém escolhe o objetivo/rótulos ← **opa, viés**
- alguém decide o que será otimizado, o que tem mais ou menos peso ← **isso é mais um viés?**

neutralidade não existe

e diferentes definições de justiça são conflitantes



justiça individual vs justiça de grupo

- justiça individual: todas as pessoas recebem o mesmo tratamento.
- justiça de grupo: todas as pessoas têm acesso ao mesmo recurso/resultado
- do ponto de vista teórico, a justiça é **impossível** (mais sobre isso semana que vem).

Fairness and worldviews

group fairness

equality of outcome



individual fairness

equality of treatment



r/ai

não existe resposta única para a justiça algorítmica

a melhor solução é **transparência** e **debate público**:

- quais critérios de justiça foram usados?
- quais testes foram conduzidos?
- podemos auditar esse sistema se necessário?

todos nós somos responsáveis

não devemos rejeitar a tecnologia, mas sim aprender que os problemas são um **misto** de tecnologia e sociedade e, portanto, não podem ser resolvidos **apenas** com tecnologia.

pra finalizar

- vieses têm múltiplas causas e fontes
- ao analisar um sistema que promete resolver tudo, precisamos sempre pensar em:
  - qual o objetivo desse sistema?
  - quem são as pessoas afetadas e como elas são afetadas?
- não existe uma solução única pra implementar uma “justiça algorítmica”

semana que vem

- como as diferentes definições de justiça são quantificadas?
- quais as métricas nos indicam como diferentes grupos são afetados por sistemas de decisão?