Ciência de Dados Responsável

Encontro 2 - Métricas de justiça

Giovana Morais

Novembro 2026

discussão rápida:

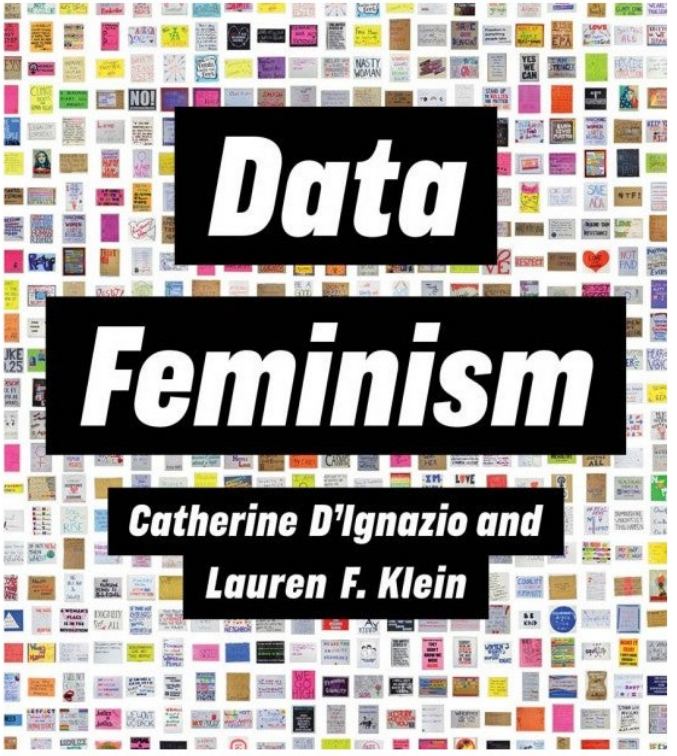
- Redata: programa que concede benefícios fiscais para a construção de data centers no Brasil
- a lei foi sancionada **sem vetos**
- debate público dia 11/11!



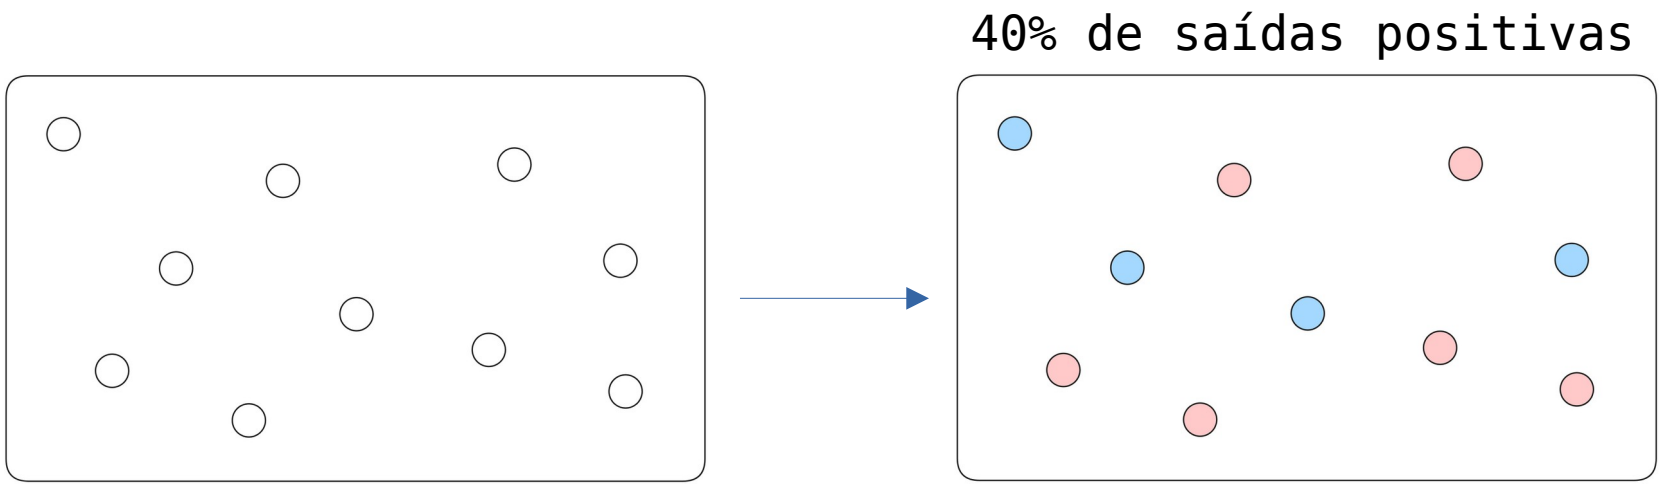
https://marcozero.org/saiba-porque-atrair-investimentos-em-data-centers-podera-ser-um-erro-do-governo-lula/

referência interessante

- cap 4: “What Gets Counted Counts”
  - discute as nuances e impactos da binarização e outras formas de ajuste de dados
- cap 5: “Unicorns, Janitors, Ninjas, Wizards, and Rock Stars”
  - discute sobre como uma pessoa só insere seus vieses em análises e como um conhecimento “completo” só é possível a partir de múltiplas perspectivas
- cap 6: “The Numbers Don’t Speak For Themselves”
  - dados não são neutros ou objetivos. contexto é absolutamente necessário para uma análise ética e de mais qualidade.

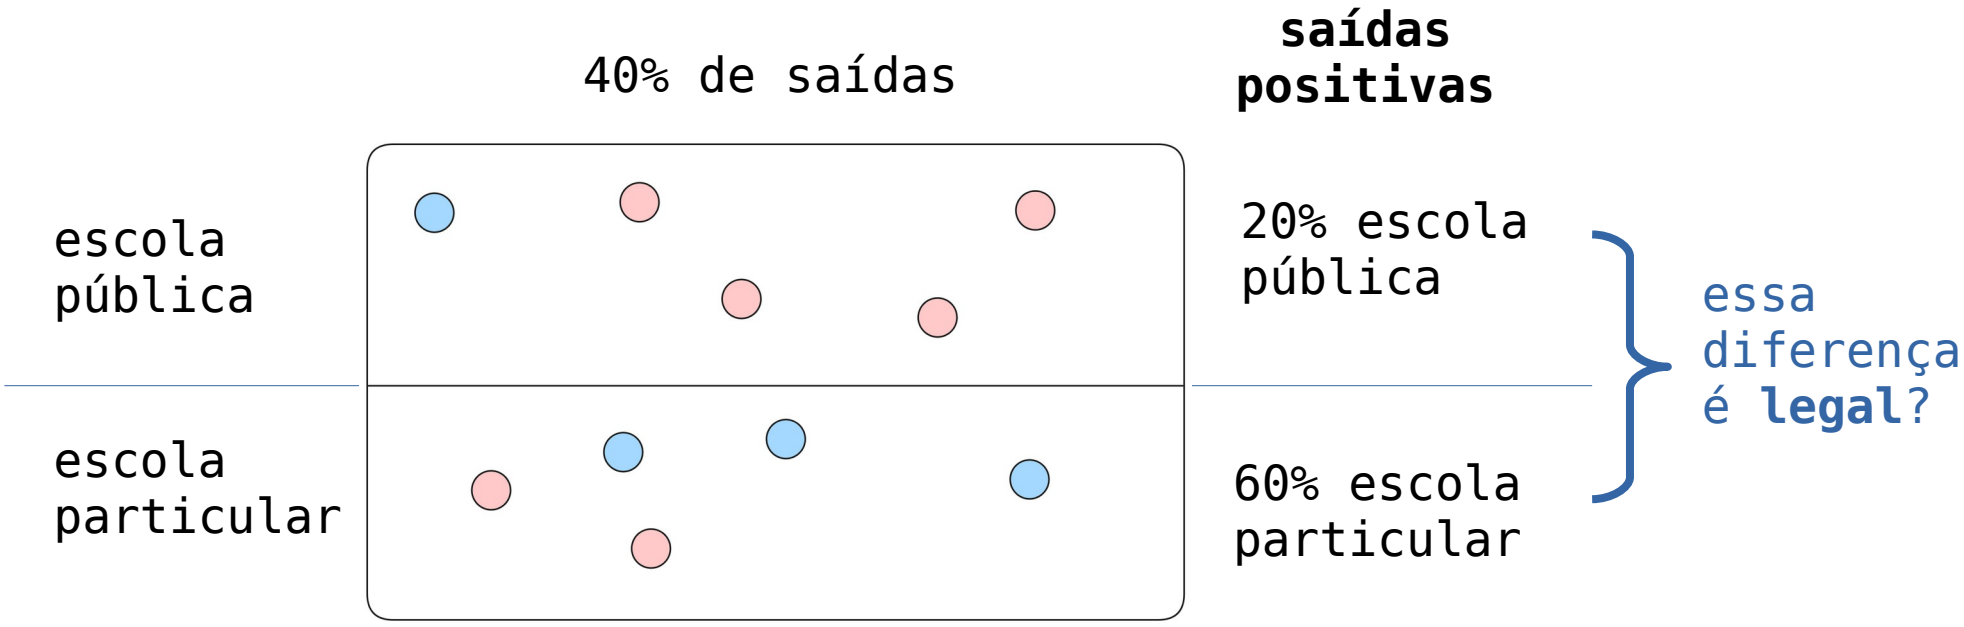


o resultado de uma população



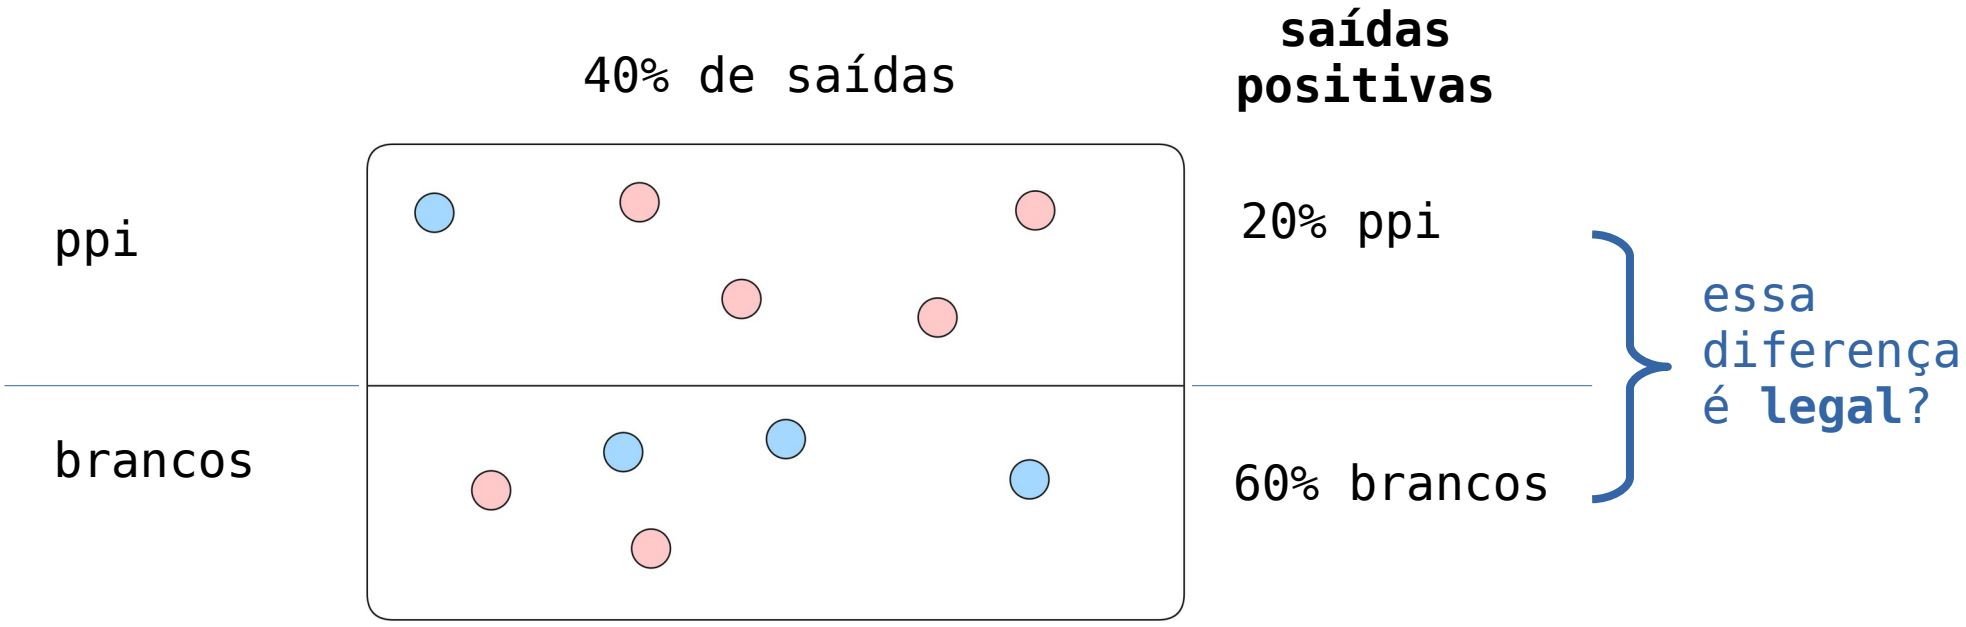
azul = resultados positivos, vermelho = resultados negativos

nem sempre reflete os resultados das **subpopulações**



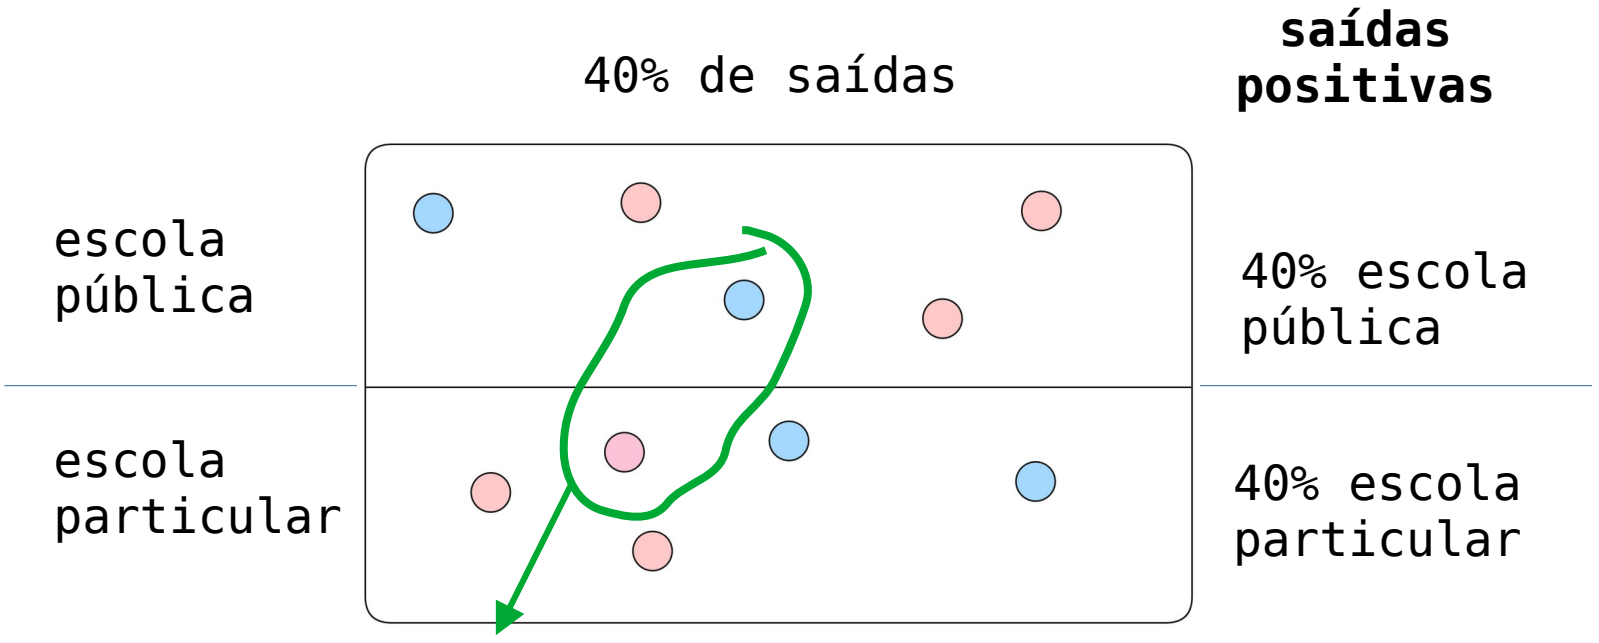
azul = resultados positivos, vermelho = resultados negativos

nem sempre reflete os resultados das **subpopulações**



azul = resultados positivos, vermelho = resultados negativos

nem sempre reflete os resultados das **subpopulações**



azul = resultados positivos, vermelho = resultados negativos

a Constituição Federal estabelece, em seu artigo 5º, o **princípio da igualdade** e a proibição de qualquer forma de **discriminação.**

traduzindo as justiças

- justiça de grupo: os resultados por subpopulação estão alinhados com os resultados da população
- justiça individual: indivíduos que são iguais **com respeito a uma tarefa** devem receber o mesmo resultado

métricas de justiça em classificação

vamos continuar falando de universidades

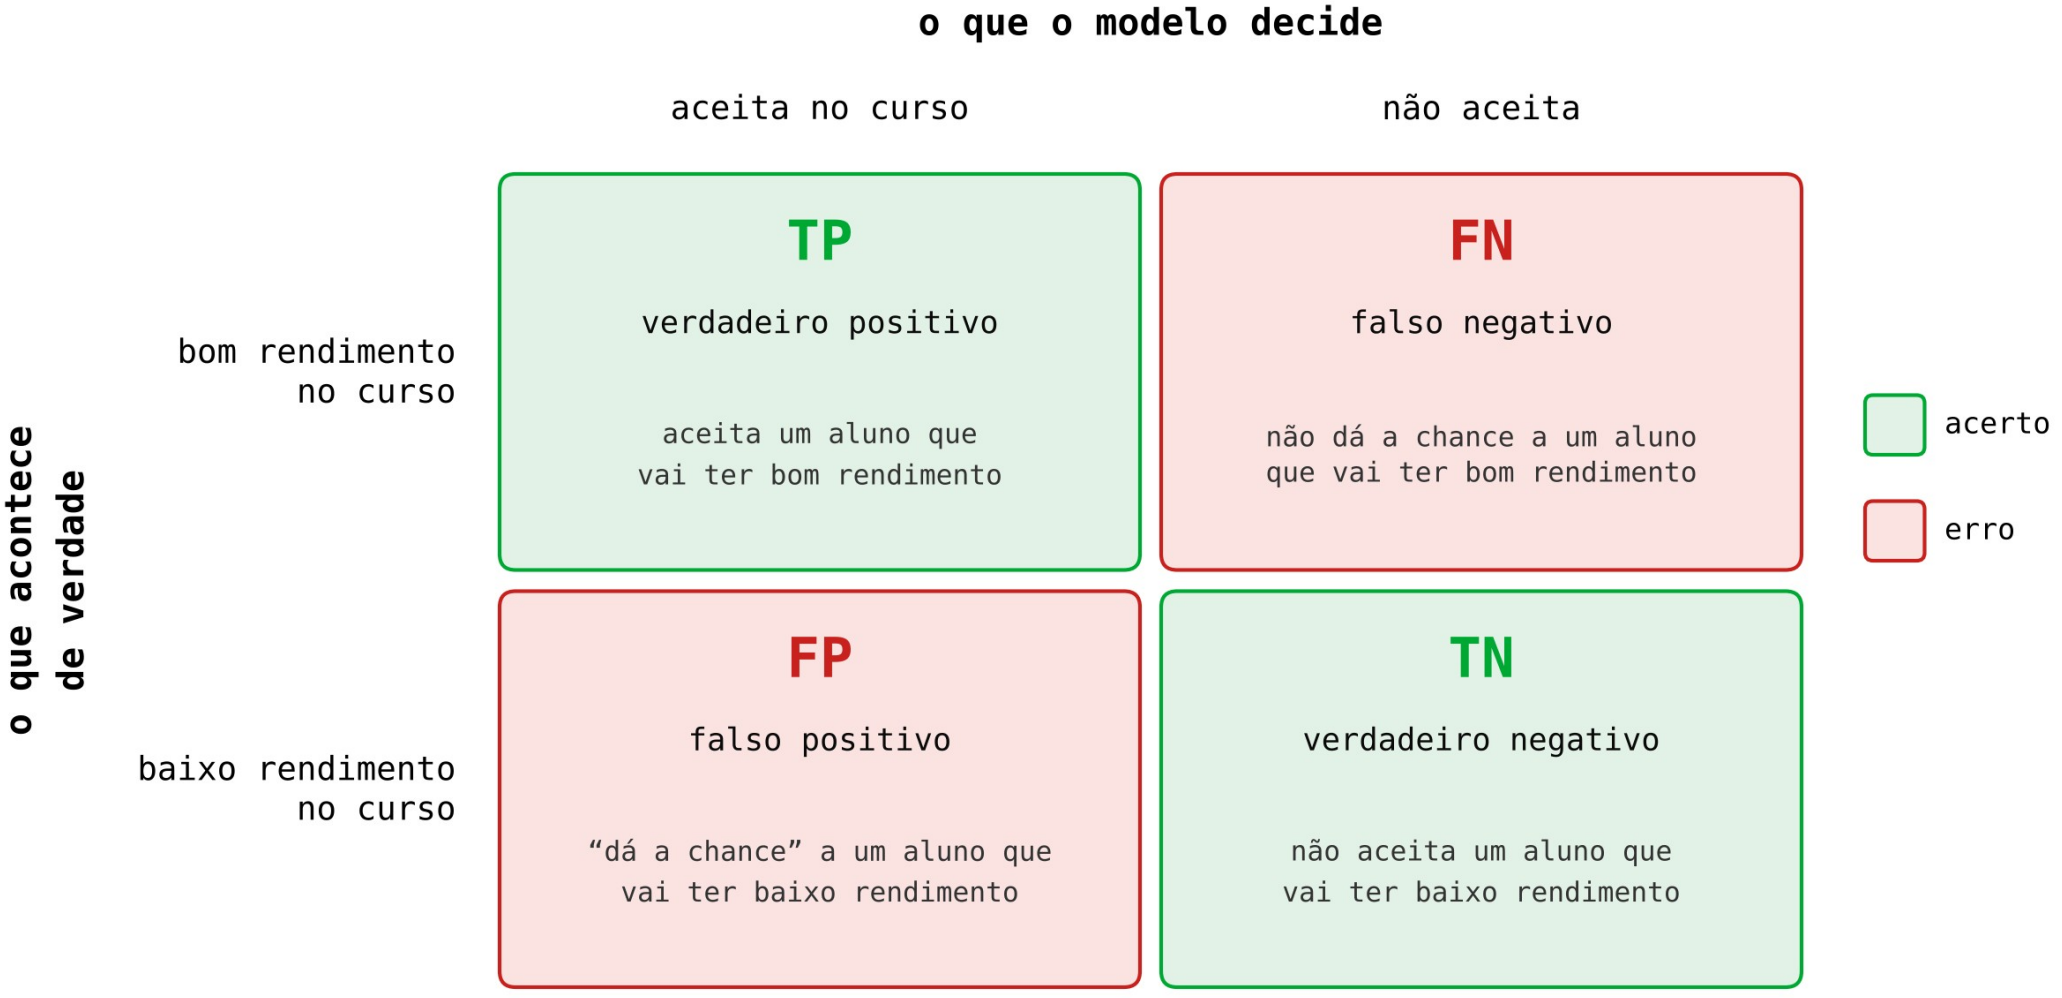
- 200 candidatos, 80 vagas
  - 100 escola particular, 100 escola pública
- modelo: qualquer regra que decide quem entra ou não na universidade

pra ter modelo, precisamos ter um rótulo: o que define o sucesso?

1) alto aproveitamento do curso (participação em entidades, networking etc)
2) alta probabilidade de conclusão de curso
3) bom desempenho no curso (IRA alto)
   - (o IRA ainda chama IRA?)

relembrando conceitos de classificação

- verdadeiro positivo (TP): o modelo acerta a predição positiva
- verdadeiro negativo (TN): o modelo acerta a predição negativa
- falso positivo (FP): o modelo erra a predição positiva
- falso negativo (FN): o modelo erra a predição negativa


o que o modelo decide
aceita no curso
não aceita
o que acontece de verdade
bom rendimento no curso
baixo rendimento no curso
TP
verdadeiro positivo
aceita um aluno que vai ter bom rendimento
FN
falso negativo
não dá a chance a um aluno que vai ter bom rendimento
FP
falso positivo
“dá a chance” a um aluno que vai ter baixo rendimento
TN
verdadeiro negativo
não aceita um aluno que vai ter baixo rendimento
acerto
erro

nosso exemplo com números

- rótulo escolhido (gt): aluno terá um IRA alto no fim do curso

	IRA alto	IRA baixo	total de alunos
escola particular	50	50	100
escola pública	30	70	100

números inventados pra aula!

escolhendo 80 candidatos

- regra A: escolhemos as 80 maiores notas
- regra B: um modelo que tem a mesma taxa de erro nos dois grupos
- regra C: 40 vagas pra cada grupo

- todos admitem 80 pessoas. qual é mais justo?

regra A: nota de corte do ENEM

	particular	pública
admitidos	55	25
admitidos com IRA alto (TP)	40	18
admitidos sem IRA alto (FP)	15	7
barrados que teriam IRA alto (FN)	10	12

regra B: erros iguais

	particular	pública
admitidos	45	35
admitidos com IRA alto (TP)	35	21
admitidos sem IRA alto (FP)	10	14
barrados que teriam IRA alto (FN)	15	9

um modelo que acerta e erra na mesma proporção nos dois grupos

regra C: 40 vagas pra cada grupo

	particular	pública
admitidos	40	40
admitidos com IRA alto (TP)	33	24
admitidos sem IRA alto (FP)	7	16
barrados que teriam IRA alto (FN)	17	6

usamos aqui as maiores notas por grupo

regra A, regra B e regra C

	regra A		regra B		regra C	
	part	púb	part	púb	part	púb
admitidos	55	25	45	35	40	40
TP	40	18	35	21	33	24
FP	15	7	10	14	7	16
FN	10	12	15	9	17	6

lembrando: 50 alunos de escola particular e 30 de escola pública teriam IRA alto (de 100 cada)

paridade demográfica

- também conhecida por paridade estatística, justiça de grupo, independência entre outros.
- intuição: todos os grupos têm que ter a mesma probabilidade de ter um resultado positivo
- P(pred = 1 | G = g) pra todo grupo g

paridade demográfica com números

- conta: admitidos / total de candidatos do grupo

	particular	pública
regra A	55%	25%
regra B	45%	35%
regra C	40%	40% ✓

só a regra C satisfaz

paridade em relação a quê? inscritos? concluintes do ensino médio? população?

regra A, regra B e regra C

	regra A		regra B		regra C	
	part	púb	part	púb	part	púb
admitidos	55	25	45	35	40	40
TP	40	18	35	21	33	24
FP	15	7	10	14	7	16
FN	10	12	15	9	17	6

lembrando: 50 alunos de escola particular e 30 de escola pública teriam IRA alto (de 100 cada)

igualdade de oportunidade

- a taxa de verdadeiros positivos (TPR) deve ser igual entre os subgrupos
- intuição: o bom candidato não é punido por causa do grupo que pertence
- P(pred = 1 | gt = 1, G = g) igual pra todo g

igualdade de oportunidade com números

- conta: TPR = TP / quantos alunos teriam IRA alto

	particular	pública
regra A	40/50 = 80%	18/30 = 60%
regra B	35/50 = 70%	21/30 = 70% ✓
regra C	33/50 = 66%	24/30 = 80%

na regra A, um bom aluno de escola pública tem **bem menos chance** (60%) que um bom aluno de escola particular (80%)

chances equalizadas

- intuição: o modelo erra da mesma forma em todos os grupos?
- exige **duas** igualdades:
  - TPR igual: bons alunos têm a mesma chance de entrar
  - FPR igual: quem não teria IRA alto tem a mesma chance de entrar “por engano”
- mais estrita que a igualdade de oportunidade (que olha apenas a TPR)
- P(pred = 1 | gt = y, G = g) igual pra todo g, com y = 0 e y = 1

chances equalizadas com números

- conta: FPR = FP ÷ quantos **não** teriam IRA alto

	particular	pública
regra A	15/50 = 30%	7/70 = 10%
regra B	10/50 = 20%	14/70 = 20% ✓
regra C	7/50 = 14%	16/70 = 23%

só a regra B tem TPR **e** FPR iguais

no vestibular, os dois erros pesam igual? barrar um bom aluno × admitir quem não teria IRA alto

paridade preditiva

- intuição: “ser admitido” significa a mesma coisa nos dois grupos?
- entre os admitidos, a proporção com IRA alto deve ser igual
- P(gt = 1 | pred = 1, G = g) igual pra todo g
- conta: PPV (precisão) = TP / admitidos

paridade preditiva com números

	particular	pública
regra A	40/55 = 73%	18/25 = 72% ✓
regra B	35/45 = 78%	21/35 = 60%
regra C	33/40 = 82%	24/40 = 60%

a nota de corte “funciona igual” pros admitidos dos dois grupos…

… mas, como vimos, barra muito mais bons alunos de escola pública

calibração por grupo

- agora o modelo dá um **score** S (ex.: probabilidade de IRA alto), não só sim/não
- intuição: um mesmo score significa a mesma coisa nos dois grupos?
- exemplo: se a previsão diz “70% de chance de chuva”, deve chover em ~70% desses dias, em Sorocaba ou em Fortaleza
- P(gt = 1 | S = s, G = g) = s pra todo g

calibração no ENEM

- alunos com nota ~700 no ENEM (números hipotéticos):
  - escola particular: 60% teriam IRA alto
  - escola pública: 75% teriam IRA alto
- o mesmo 700 **não** significa a mesma coisa
- quem chegou a 700 com menos recursos pode ter mais potencial
- um modelo calibrado daria scores **diferentes** pra notas iguais

qual regra é justa?

	paridade demográfica	igualdade de oportunidade	chances equalizadas	paridade preditiva
regra A (nota)	✗	✗	✗	✓
regra B (erros iguais)	✗	✓	✓	✗
regra C (40 + 40)	✓	✗	✗	✗

nenhuma regra satisfaz tudo

não é falta de esforço

- quando as taxas base são diferentes (50% IRA alto vs 30% IRA alto), é matematicamente impossível satisfazer tudo ao mesmo tempo
  - erros iguais → “ser admitido” significa coisas diferentes
  - “ser admitido” significando o mesmo → erros diferentes
- escolher uma métrica é escolher **quem arca com o erro**
- Kleinberg et al. (2016); Chouldechova (2017)

quanto custa ser justo?

- bons alunos (IRA alto) admitidos no total:
  - regra A: 58
  - regra B: 56
  - regra C: 57
- a diferença na “qualidade” da turma é pequena
- a diferença em quem entra (em termos da demografia) é grande

os números foram construídos, mas a pergunta vale pra casos reais! e aqui nem estamos ainda falando de interseccionalidade

voltando ao rótulo

- por que 50% × 30%?
- é um fato sobre os alunos ou sobre as condições que eles tiveram?
  - preparação pra prova
  - precisar trabalhar durante o curso
  - apoio da universidade (bolsa, moradia, monitoria)
- a universidade ajuda a produzir o rótulo
- otimizar pra dados históricos pode **reproduzir** a desigualdade

resumo

métrica	intuição	definição	como medir
paridade demográfica	grupos aprovados na mesma proporção	pred ⊥ G	P(pred=1 | G=g)
igualdade de oportunidade	bons candidatos têm a mesma chance	pred ⊥ G | gt=1	TPR por grupo
chances equalizadas	o modelo erra igual nos grupos	pred ⊥ G | gt	TPR e FPR por grupo
paridade preditiva	“admitido” significa o mesmo	gt ⊥ G | pred=1	PPV por grupo
calibração por grupo	o score significa o mesmo	gt ⊥ G | S	P(gt=1 | S=s, G=g) = s

métricas de justiça em ranking

ranking

- na classificação, a ordem não importa
- em ranking, a ordem importa: normalmente olhamos só os k primeiros (o “top-k”)
- o vestibular já é um ranking: a lista de classificação com corte em 80 vagas é um **top-80**

conceitos base

- **viés de posição**: a atenção cai rápido ao descer na lista
  - qual foi a última vez que você olhou a página 2 do Google?
- **exposição**: quanta atenção cada posição recebe
  - modelo usual: peso da posição $i = 1 / \log_2(1 + i)$

posição	1	2	3	5	10
peso	1,00	0,63	0,50	0,39	0,29

estar na lista != ser visto

- uma professora recebe 10 candidatos a uma bolsa de IC e lê de cima pra baixo
- 5 de escola particular (P), 5 de escola pública (U), todos igualmente qualificados
- ordem P P P P P U U U U U
  - representação: 50% / 50%
  - exposição: particular fica com **~65%** da atenção
- ordem alternada P U P U P U P U P U
  - particular ainda fica com **~55%**
  - quem está em 1º sempre leva vantagem

representação no top-k

- intuição: em cada pedaço do topo, os grupos aparecem de forma razoável?
- vale pra **cada** prefixo: top-5, top-20, top-80
- no ENEM (regra A):
  - top-80: 55 de escola particular, 25 de escola pública
  - top-20 (bolsas de mérito, escolha de turno…): e se fossem 18 × 2?
- exemplo: a prateleira na altura dos olhos no supermercado

exposição proporcional à relevância

- não queremos atenção **igual**, mas sim atenção **justa**
- a exposição de cada grupo deve ser proporcional a quantos candidatos relevantes ele tem
- no ENEM: dos 80 alunos com IRA alto, 30 são de escola pública (37,5%)
  - eles deveriam receber ~37,5% da atenção
- é a versão em ranking da **igualdade de oportunidade**
- Singh & Joachims (2018)

equidade amortizada

- dois candidatos igualmente bons não podem estar em 1º ao mesmo tempo
- …mas podem se revezar ao longo de vários rankings
- funciona pra buscas e recomendações
- funciona pro vestibular? pro candidato, aquele ano pode ser a única chance
- Biega et al. (2018)

classificação × ranking

ideia	classificação	ranking
os grupos aparecem na mesma proporção	paridade demográfica	representação no top-k
quem merece tem a mesma chance	igualdade de oportunidade	exposição ∝ relevância
casos parecidos, tratamento parecido	justiça individual	equidade amortizada

em cenários de ranking, mantemos as mesmas ideias de antes, mas acrescentamos a **posição**

resumão

- não existe métrica “neutra”
- escolher uma métrica é escolher quem arca com o erro
- a mesma métrica pode ser justa num contexto e injusta em outro
- antes de escolher a métrica, sempre questione **de onde vem o rótulo?**